CSV mit reinem SQL & der Magie von JSON_TABLE einlesen

17. November 2016

Robert Marz

Robert Marz

Kunde

- Technical Architect
  mit datenbankzentrischem Weltbild

its-people

- Portfoliomanager Datenbanken
- Blogredakteur

DOAG

- Themenverantwortlicher „Cloud“
  in der Datenbank Community

@RobbieDatabee

blog.its-people.de

Robert.Marz
@its-people.de

its-people auf der DOAG 2016

- Quo vadis datum?
  Data Lineaging in gewachsenen Warehouse-Strukturen
  - Jens Behring
  - Dienstag, 15.11. 13:00 Uhr Helsinki
- **CSV mit reinem SQL und der Magie von JSON_TABLE einlesen**
  - Robert Marz
  - Dienstag, 15.11 14:00 Uhr Oslo
- Eine Karte sagt mehr als 1000 Worte
  - Sven Brömer
  - Mittwoch 16.11. 12:00 Uhr Oslo
- Scripting mit SQLcl
  Batchscripts auf einem neuen Level
  - Sabine Heimsath, Robert Marz
  - Mittwoch, 16.11. 14:00 Uhr Kopenhagen
- Panel:
  Der DBA in der Cloud
  - Moderator Robert Marz
  - Donnerstag, 17.11. 10:00 Uhr Kiew
- Werkzeuge für DBAs und Cloudnutzer: ssh
  - Robert Marz
  - Donnerstag, 17.11. 16:00 Uhr Oslo

Motivation

CSV-Daten sind allgegenwärtig

PL/SQL ist umständlich

Ask Tom Frage:

parsing a CLOB field which contains CSV data

CSV Dateien

gewachsenes Format

```
Eins,Zwei,Drei
Vier,Fünf
Sechs,Sieben,Acht
```

Ein bisschen standardisiert:

- RFC4180 für CSV

JSON Dateien

Natives Format von JavaScript	"XML mit Klammern statt Tags"
Schemaless	Unstrukturierte Daten
	Parser prüft nicht gegen DTD
Strukturen	{} - Objekt
	[] - Array
Zuweisung	"Variable" : "Wert"

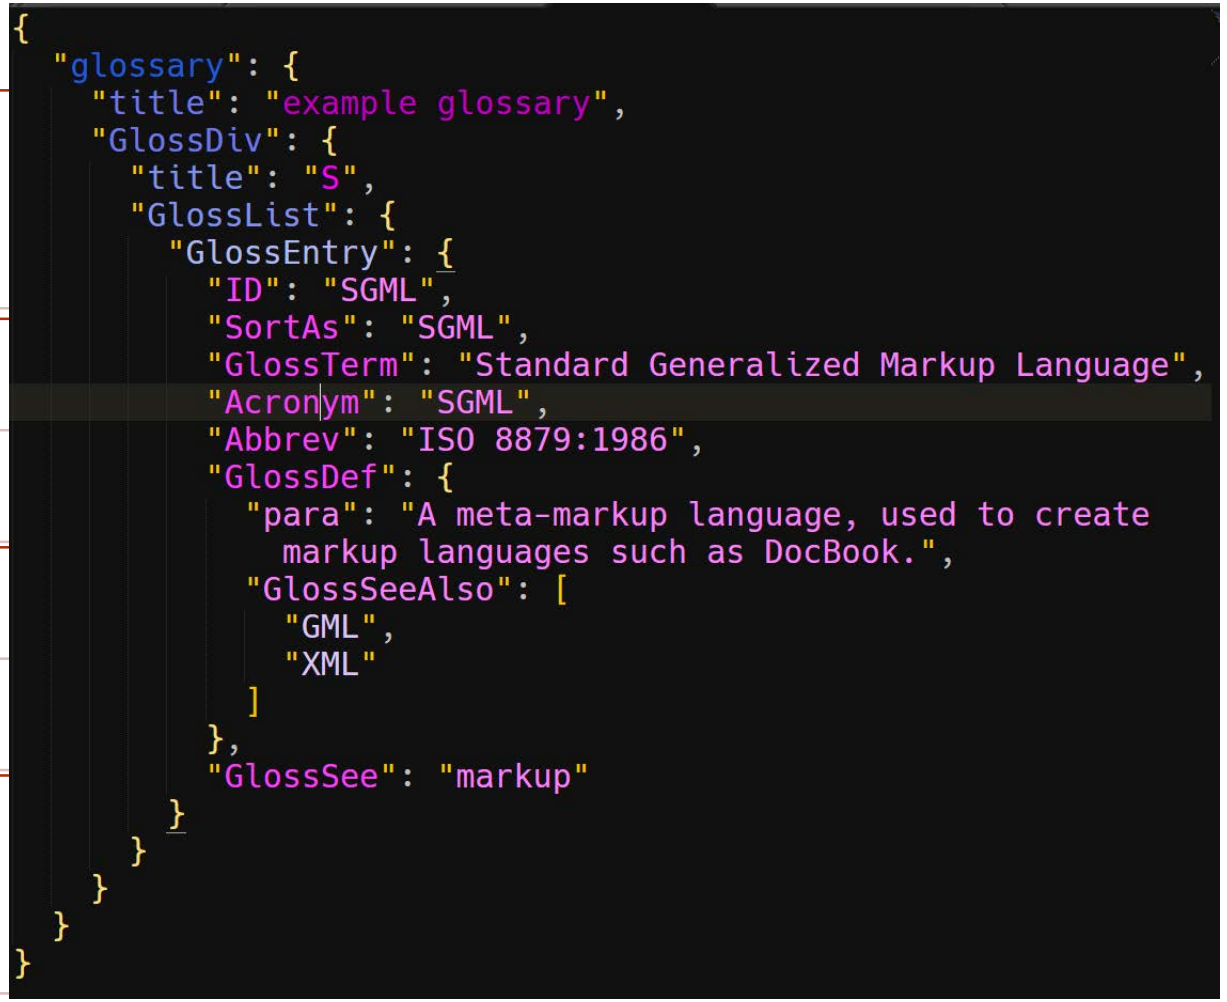

```
{
  "glossary": {
    "title": "example glossary",
    "GlossDiv": {
      "title": "S",
      "GlossList": {
        "GlossEntry": {
          "ID": "SGML",
          "SortAs": "SGML",
          "GlossTerm": "Standard Generalized Markup Language",
          "Acronym": "SGML",
          "Abbrev": "ISO 8879:1986",
          "GlossDef": {
            "para": "A meta-markup language, used to create
              markup languages such as DocBook.",
            "GlossSeeAlso": [
              "GML",
              "XML"
            ]
          },
          "GlossSee": "markup"
        }
      }
    }
  }
}
```

JSON Datentypen

JSON	String	"text" : "Hallo Welt"
	Zahl	"integer" : 12345
		"double" : 123.45
		"float" : 1.234e-6
	Boolean	„Wahr" : true
		„Falsch" : false
		"Unbestimmt" : null
	RFC7159 für JSON	

Vergleich JSON - CSV

```
Eins,Zwei,Drei
Vier,Fünf
Sechs,Sieben,Acht
```

```
["Eins", "Zwei", "Drei"
,"Vier", "Fünf"
, "Sechs", "Sieben", "Acht"]
```

Der JSON_TABLE Operator

JSON_TABLE

Lebt in der SQL-From-Clause

Produziert **Zeilen** und **Spalten**

Akzeptiert JSON aus CLOBs

Aufnahme in den SQL-Standard

Der JSON_TABLE Operator

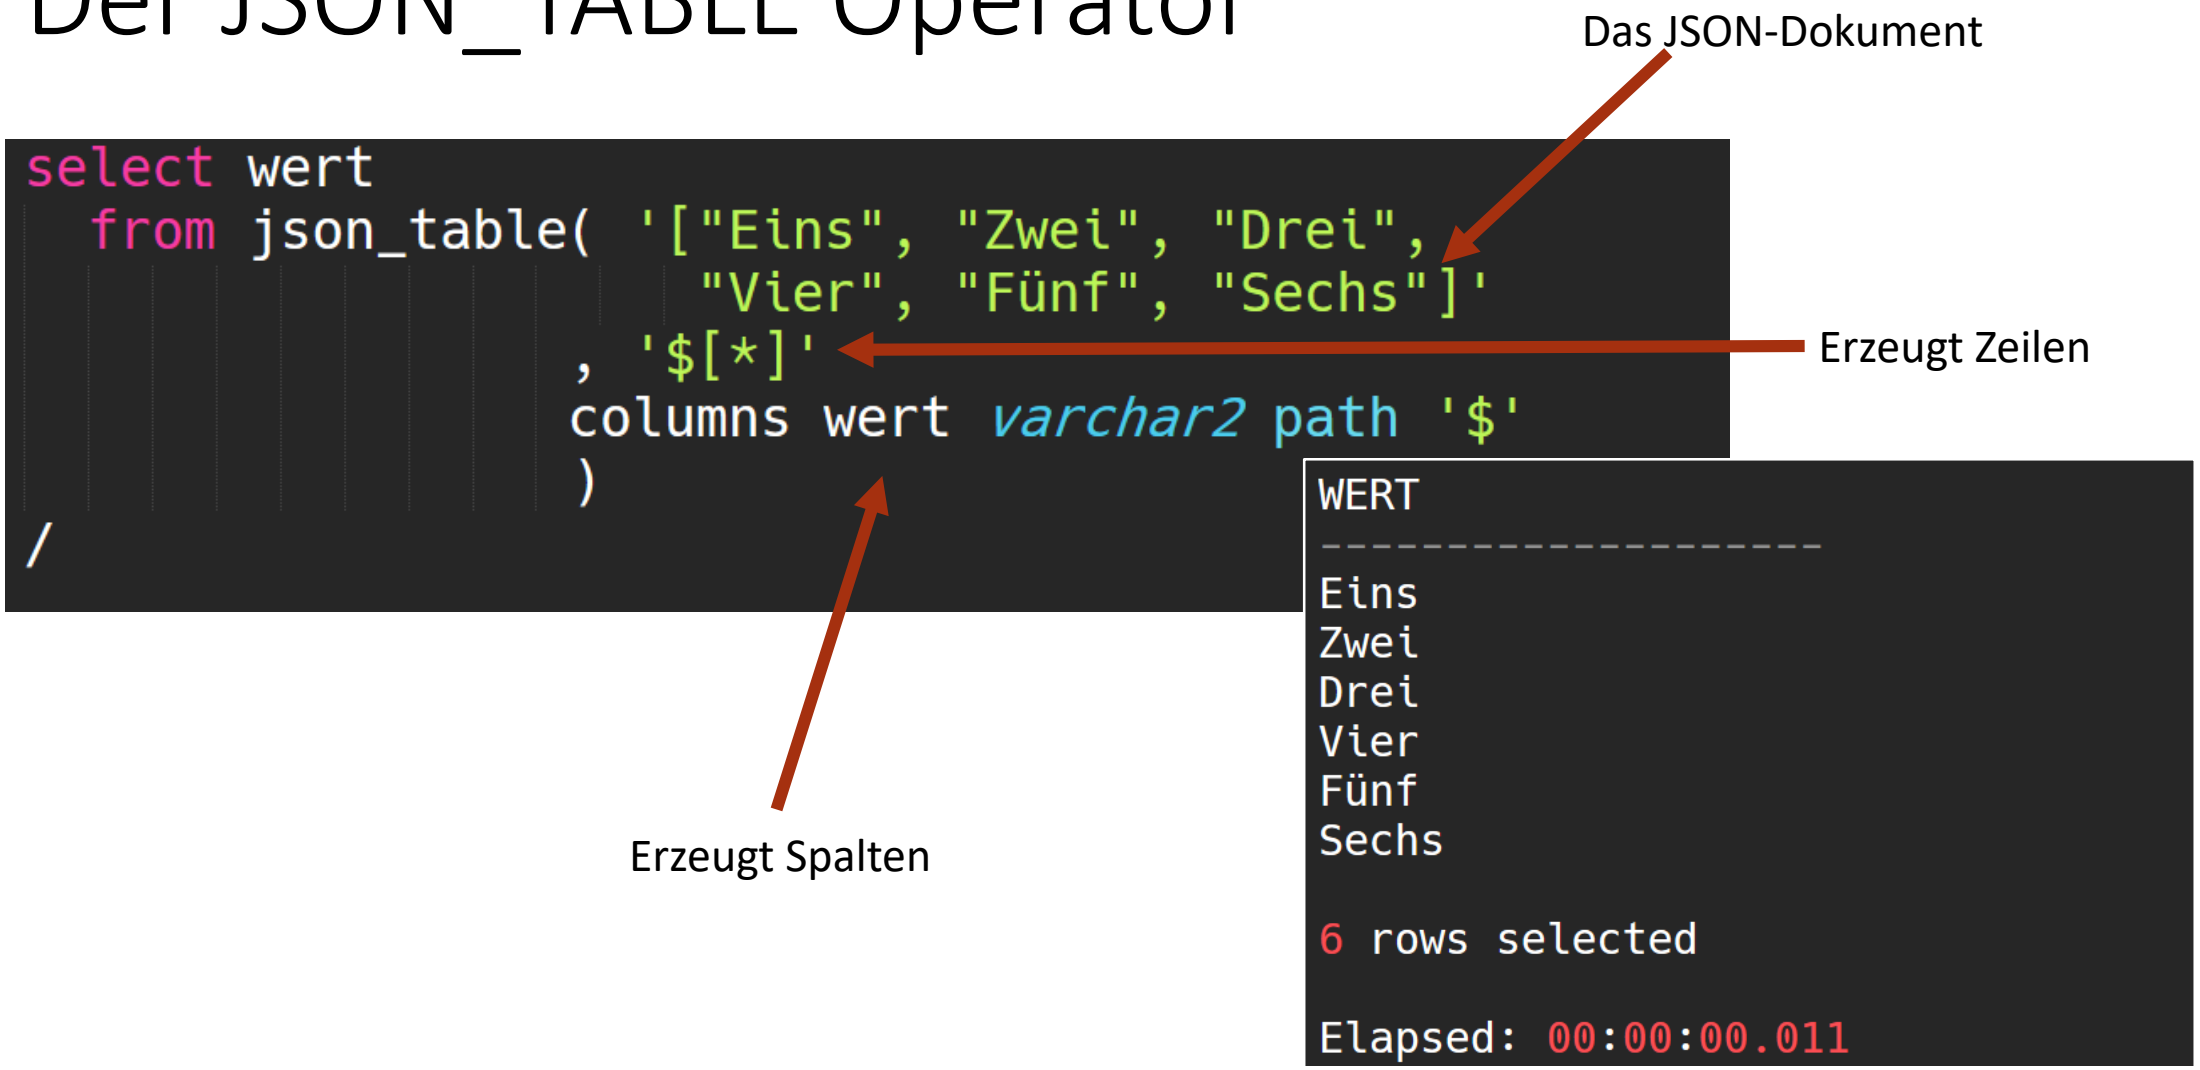

Überführen von CSV nach JSON

Anforderung

erhalten der Zeilen- und Spaltenstruktur

Lösung

geschachteltes JSON-Array

```
[
  ["Eins", "Zwei", "Drei"]
, ["Vier", "Fünf"]
, [ "Sechs", "Sieben", "Acht"]
]
```

Die REGEXP_REPLACE-Funktion

REGEXP_REPLACE	Lebt in der	SQL-Select-List
		Where-Clause
	Arbeitet wie replace()	reguläre Ausdrücke statt statischer Strings
	Akzeptiert CLOBs	

Reguläre Ausdrücke - Kurzüberblick

RegExp in kurz und schnell geht nicht.

Google: RegExp Tutorial|Einführung|Tipps

https://www.cheatography.com/davechild/cheat-sheets/regular-expressions/pdf/

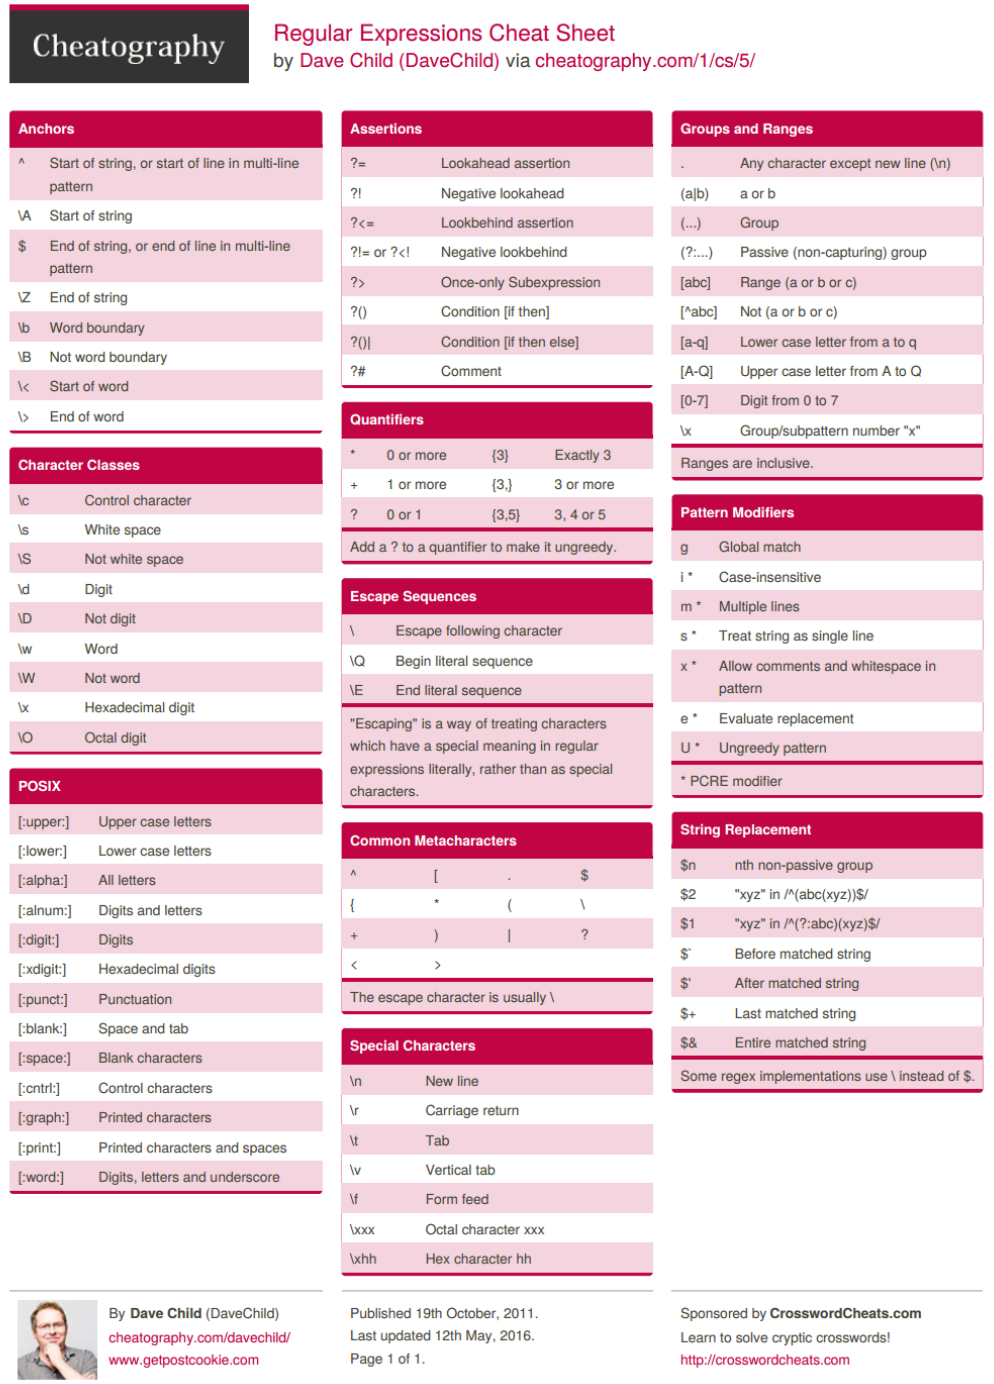

Cheatography

Regular Expressions Cheat Sheet
by Dave Child (DaveChild) via cheatography.com/1/cs/5/

Anchors

^	Start of string, or start of line in multi-line pattern
\A	Start of string
$	End of string, or end of line in multi-line pattern
\Z	End of string
\b	Word boundary
\B	Not word boundary
\<	Start of word
\>	End of word

Character Classes

\c	Control character
\s	White space
\S	Not white space
\d	Digit
\D	Not digit
\w	Word
\W	Not word
\x	Hexadecimal digit
\O	Octal digit

POSIX

[:upper:]	Upper case letters
[:lower:]	Lower case letters
[:alpha:]	All letters
[:alnum:]	Digits and letters
[:digit:]	Digits
[:xdigit:]	Hexadecimal digits
[:punct:]	Punctuation
[:blank:]	Space and tab
[:space:]	Blank characters
[:cntrl:]	Control characters
[:graph:]	Printed characters
[:print:]	Printed characters and spaces
[:word:]	Digits, letters and underscore

Assertions

?=	Lookahead assertion
?!	Negative lookahead
?<=	Lookbehind assertion
?!= or ?<!	Negative lookbehind
?>	Once-only Subexpression
?()	Condition [if then]
?()|	Condition [if then else]
?#	Comment

Quantifiers

*	0 or more	{3}	Exactly 3
+	1 or more	{3,}	3 or more
?	0 or 1	{3,5}	3, 4 or 5

Add a ? to a quantifier to make it ungreedy.

Escape Sequences

\	Escape following character
\Q	Begin literal sequence
\E	End literal sequence

"Escaping" is a way of treating characters which have a special meaning in regular expressions literally, rather than as special characters.

Common Metacharacters

^	[	.	$
{	*	(	\
+	)	|	?
<	>		

The escape character is usually \

Special Characters

\n	New line
\r	Carriage return
\t	Tab
\v	Vertical tab
\f	Form feed
\xxx	Octal character xxx
\xhh	Hex character hh

Groups and Ranges

.	Any character except new line (\n)
(a|b)	a or b
(...)	Group
(?:...)	Passive (non-capturing) group
[abc]	Range (a or b or c)
[^abc]	Not (a or b or c)
[a-q]	Lower case letter from a to q
[A-Q]	Upper case letter from A to Q
[0-7]	Digit from 0 to 7
\x	Group/subpattern number "x"

Ranges are inclusive.

Pattern Modifiers

g	Global match
i *	Case-insensitive
m *	Multiple lines
s *	Treat string as single line
x *	Allow comments and whitespace in pattern
e *	Evaluate replacement
U *	Ungreedy pattern

* PCRE modifier

String Replacement

$n	nth non-passive group
$2	"xyz" in /^(abc(xyz))$/
$1	"xyz" in /^(?:abc)(xyz)$/
$`	Before matched string
$'	After matched string
$+	Last matched string
$&	Entire matched string

Some regex implementations use \ instead of $.

By **Dave Child** (DaveChild)
cheatography.com/davechild/
www.getpostcookie.com

Published 19th October, 2011.
Last updated 12th May, 2016.
Page 1 of 1.

Sponsored by **CrosswordCheats.com**
Learn to solve cryptic crosswords!
http://crosswordcheats.com

JSON Umwandlung: Array - Zeilenanfang

```
with
  csv as (
           select to_clob( '"eins", "zwei", "drei"'||chr(10)
                         || '"vier", "fünf", "sechs"'||chr(10)
                         || '"sieben", "acht", "neun"'||chr(10)
                          ) blb
             from dual
         )
, jsn1 as (  -- Zeilenanfang
            select regexp_replace( blb
                                 , '^'
                                 ,'['
                                 ,1,0,'m'
                                 ) blb
              from csv
         )
```

```
BLB
----------------------------------------
["eins", "zwei", "drei"
["vier", "fünf", "sechs"
["sieben", "acht", "neun"
```

JSON Umwandlung: Array - Zeilenende

```
, jsn1 as (  -- Zeilenanfang
           select regexp_replace( blb
                                , '^'
                                ,'['
                                ,1,0,'m'
                                ) blb
             from csv
         )
, jsn2 as (  -- Zeilenende
           select regexp_replace( blb
                                , '$'
                                ,']'
                                ,1,0,'m'
                                ) blb
             from jsn1
)
```

```
BLB
------------------------------------
["eins", "zwei", "drei"]
["vier", "fünf", "sechs"]
["sieben", "acht", "neun"]
```

JSON Umwandlung: Kommas zwischen Zeilen

```
, jsn2 as (  -- Zeilenende
             select regexp_replace( blb
                                  , '$'
                                  ,']'
                                  ,1,0,'m'
                                  ) blb
               from jsn1
)
, jsn3 as (  -- Kommas zwischen Zeilen
             select regexp_replace('['||blb||']'
                                  , '\]'||chr(10)||'\['
                                  , '],['
                                  ,1,0,''
                                  ) blb
               from jsn2
)
```

```
BLB
--------------------------------------------------------------------------------
[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]
]
```

Das konvertierte JSON abfragen

```
with
  csv as (
           select to_clob( '"eins", "zwei", "drei"'||chr(10)
                         || '"vier", "fünf", "sechs"'||chr(10)
                         || '"sieben", "acht", "neun"'||chr(10)
                          ) blb
             from dual
         )
, jsn1 as ( -- Zeilenanfang
--...
, jsn2 as ( -- Zeilenende
-- ...
, jsn3 as ( -- Kommas zwischen Zeilen
-- ...
select zeile
     , spalte
     , wert
     , blb
  from jsn3
     , json_table( blb
                 , '$[*]'
                 columns ( zeile for ordinality
                         , NESTED PATH '$[*]'
                           COLUMNS ( wert varchar2 PATH '$'
                                   , spalte for ordinality
                                   )
                         )
                 )
order by zeile
;
```

CSV einlesen: Zwischenergebnis

ZEILE	SPALTE	WERT	BLB
1	1	eins	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
1	2	zwei	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
1	3	drei	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
2	1	vier	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
2	2	fünf	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
2	3	sechs	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
3	1	sieben	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
3	2	acht	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]
3	3	neun	[["eins", "zwei", "drei"],["vier", "fünf", "sechs"],["sieben", "acht", "neun"]]

9 rows selected.

Pivotieren - SQL-Style

```
select zeile
      , max(decode(spalte,1, wert)) spalte_1
      , max(decode(spalte,2, wert)) spalte_2
      , max(decode(spalte,3, wert)) spalte_3
from(
with
  csv as (
-- ...
)
group by zeile
;
```

Pivotieren mit der Magie von JSON_TABLE

```
with
  csv as (
           select to_clob( '"eins", "zwei", "drei"'||chr(10)
                         || '"vier", "fünf", "sechs"'||chr(10)
                         || '"sieben", "acht", "neun"'||chr(10)
                         ) blb
             from dual
         )
, jsn1 as (  -- Zeilenanfang
-- ...
, jsn2 as (  -- Zeilenende
-- ...
, jsn3 as (  -- Kommas zwischen Zeilen
-- ...
select zeile, spalte1, spalte2, spalte3
  from jsn3
     , json_table( blb
                 , '$[*]'
                 columns ( spalte1 varchar2 PATH '$[0]'
                         , spalte2 varchar2 PATH '$[1]'
                         , spalte3 varchar2 PATH '$[2]'
                         , zeile for ordinality
                         )
                 )
;
```

CSV einlesen: Endergebnis

```
32  )
33  select zeile, spalte1, spalte2, spalte3
34    from jsn3
35       , json_table( blb
36                   , '$[*]'
37                   columns ( spalte1 varchar2 PATH '$[0]'
38                           , spalte2 varchar2 PATH '$[1]'
39                           , spalte3 varchar2 PATH '$[2]'
40                           , zeile for ordinality
41                           )
42*                  )

    ZEILE SPALTE1         SPALTE2         SPALTE3
--------- --------------- --------------- ---------------
        1 eins            zwei            drei
        2 vier            fünf            sechs
        3 sieben          acht            neun
```

Performancebetrachtung

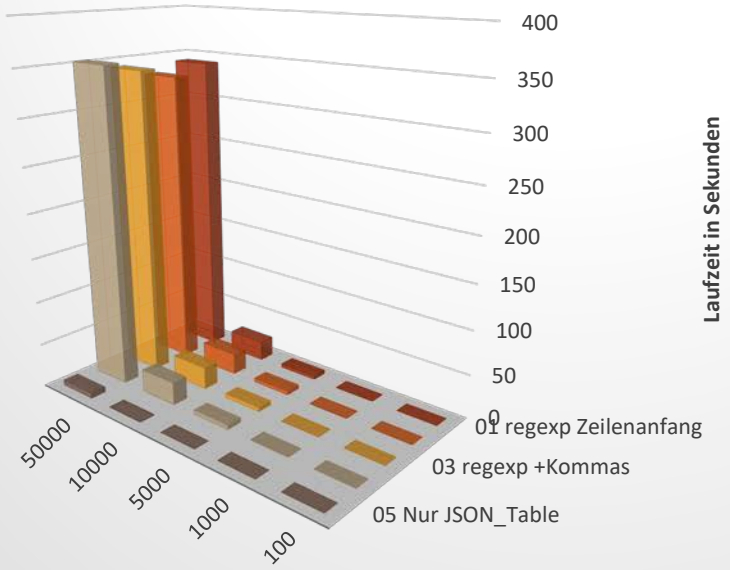

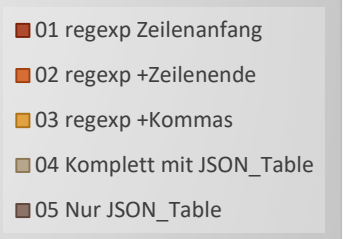

	100	1000	5000	10000	50000
01 regexp Zeilenanfang	0,056766	0,399368	4,105005	22,349163	340,967708
02 regexp +Zeilenende	0,071818	0,482135	4,416	24,190292	330,623893
03 regexp +Kommas	0,041861	0,455138	4,611022	25,33887	342,201978
04 Komplett mit JSON_Table	0,050579	0,503539	5,14075	26,035794	352,348599
05 Nur JSON_Table	0,015129	0,024825	0,178398	0,760695	5,840169

Anzahl Zeilen

Blobs vom Client in die Datenbank laden

SQLcl ist das neue SQL*Plus

Scripts in JavaScript möglich

- its-people Vortrag Mittwoch, 16.11. 14:00

Beispiel

- Laden von Blobs

```
var HashMap = Java.type("java.util.HashMap");
var bindmap = new HashMap();

// Wir erwarten ein Argument: Den Dateinamen
ctx.write("Lese Datei: "+ args[1] + "\n");
var filePath=args[1];

var blob=conn.createClob();
var bstream=blob.setAsciiStream(1);
/* den Blob einlesen */
java.nio.file.Files.copy( java.nio.file.FileSystems.getDefault().getPath(
    filePath)
                        , bstream );
bstream.flush();

bindmap.put("csv",  blob);
bindmap.put("pfad", filePath);
if(!util.execute( "insert into csv_tab(csv,pfad) values(:csv, :pfad)"
                , bindmap)
  ){ ctx.write("insert fehlgeschlagen exit.\n");
     exit;
}
sqlcl.setStmt( "commit; \n"
             + "set sqlformat ansiconsole \n"
             + " select pfad,dbms_lob.getlength(csv) "
             + "from csv_tab;");
sqlcl.run();
```

Demo\12a_Blob_einlesen_mit_sqlcl.js

CSV einlesen - Demo

DEMO

Ressourcen

Quellen für Folien und Demos:

- DOAG Website / Konferenzplaner
- http://www.its-people.de/doag-2016
- https://github.com/its-people/csv-json_table

Fazit

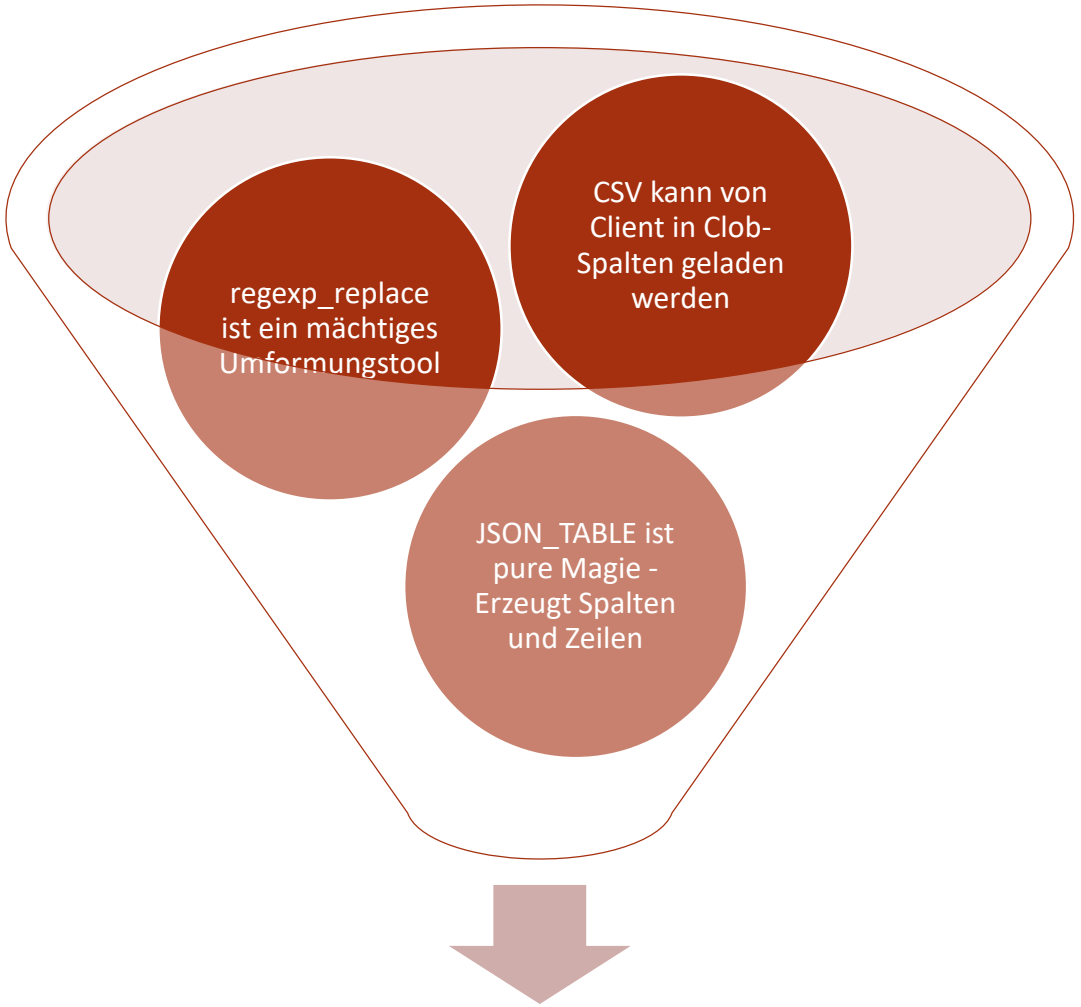

PL/SQL ist gut. SQL ist besser.

Herzlichen Dank für Ihre Aufmerksamkeit !

we make the difference
www.its-people.de

Fragen ?

its-people GmbH

Frankfurt	Tel. 069 2475 2100
Hamburg	Tel. 040 2360 8808
Köln	Tel. 0221 1602 5204
München	Tel. 089 5484 2401

its-people ERP Beratungsgesellschaft mbH

Frankfurt	Tel. 069 2475 1980

www.its-people.de **info@its-people.de**